

SPRAWOZDANIE

z ćwiczenia nr 5

“Sztuczne sieci neuronowe”

Przedmiot: Wprowadzenie do Sztucznej Inteligencji

Imię i nazwisko: Viktoriia Nowotka, Karol Łukasik

W ramach laboratorium zaimplementowano algorytm sztucznej sieci neuronowej w postaci klasy Neural Network, która podczas inicjalizacji przyjmuje jako parametry strukturę sieci (dowolna liczba warstw, neuronów i funkcji aktywacji), maksymalną liczbę iteracji uczenia i parametr learning rate.

Na początku sieć losuje wagi z rozkładu normalnego, gdzie większość wag znajduje się w przedziale $[-\sqrt{(2/n_{in})}, +\sqrt{(2/n_{in})}]$, a bias jest inicjalizowany się jako 0.

Następnie dane wejściowe przechodzą przez wszystkie warstwy sieci neuronowej, aż do warstwy wyjściowej, gdzie otrzymujemy wektor z prawdopodobieństwami przynależności do danych klas.

Jako funkcję straty zastosowano entropię krzyżową. Gradienty wag są obliczane z wykorzystaniem propagacji wstecznej, a parametry sieci są aktualizowane algorytmem stochastyczny gradientu prostego (stochastic gradient descent).

Dane podzielono na 3 zbiory (treningowy, walidacyjny i testowy) w proporcjach 70:15:15. Zaimplementowano jedną z metod walczenia z przeuczeniem modelu – wczesne zatrzymanie uczenia. Gdy algorytm zauważy tendencję wzrostu średniego odchylenia na predykcji wyników danych walidacyjnych uczenie przerywa się.

Dla analizy dokładności modelu także stworzono parę statystycznych metod: obliczenie średniego odchylenia, obliczenie dokładności zgadywania oraz dokładność zgadywania każdej z etykiet.

Aby ograniczyć wpływ losowej inicjalizacji wag, dla każdej konfiguracji hiperparametrów obliczono średnią dokładność dla 25 różnych wartości seed (42–66). Zbadano wpływ struktury sieci oraz poziom learning rate na dokładność klasyfikacji.

Struktury sieci neuronowej opisywane w badaniach w dalszej części sprawozdania wyglądają następująco:

```


59 nn_params_list = [
60     [
61         {"neurons": inputs, "activation": relu},
62         {"neurons": 36, "activation": relu},
63         {"neurons": 16, "activation": relu},
64         {"neurons": outputs, "activation": softmax},
65     ],
66     [
67         {"neurons": inputs, "activation": relu},
68         {"neurons": 36, "activation": relu},
69         {"neurons": outputs, "activation": softmax},
70     ],
71     [
72         {"neurons": inputs, "activation": relu},
73         {"neurons": 16, "activation": relu},
74         {"neurons": outputs, "activation": softmax},
75     ],
76     [
77         {"neurons": inputs, "activation": tanh},
78         {"neurons": 16, "activation": tanh},
79         {"neurons": outputs, "activation": softmax},
80     ],
81     [
82         {"neurons": inputs, "activation": relu},
83         {"neurons": 16, "activation": tanh},
84         {"neurons": outputs, "activation": softmax},
85     ],
86     [
87         {"neurons": inputs, "activation": relu},
88         {"neurons": outputs, "activation": softmax},
89     ],
90 ]

```

Badane struktury mają różną liczbę warstw (2, 3, 4), różną liczbę neuronów w każdej warstwie ukrytej (ale zawsze liczba wejść równa liczbie wymiarów problemu, a liczba neuronów w warstwie wyjściowej równa liczbie unikalnych etykiet do klasyfikacji) i różne funkcje aktywacji. Na warstwie wyjściowej zawsze stosujemy funkcje aktywacji softmax.

Wykresy dla sztucznej sieci neuronowej bez wczesnego zatrzymania


Zbadano jaki wpływ mają różne struktury sieci na dokładność klasyfikacji wina. Zastosowane hiperparametry $l_rate = 0.005$, a $n_epoch = 10000$.



Na wykresie widzimy, że dokładność różnych struktur sztucznych sieci neuronowych (które raczej podatne na przeuczenie) krąży w okolicach 60%.

Dwuwarstwowy perceptron ma najlepszą dokładność i najmniejsze odchylenia kwadratowe.

Dla struktury sieci neuronowej z najlepszą dokładnością (dwuwarstwowy perceptron) zbadano wpływ learning rate ze zbioru [0.001, 0.005, 0.01, 0.015, 0.02, 0.05, 0.1].



Na podstawie wygenerowanego wykresu widzimy małą zmianę dokładności dla $l_rate \in [0.015, 0.02, 0.05, 0.1]$.

```
Accuracy on best structure + best l_rate: 0.61


Label 0: recall = 0.00
Label 1: recall = 0.00
Label 2: recall = 0.72
Label 3: recall = 0.67
Label 4: recall = 0.26
Label 5: recall = 0.00

Process finished with exit code 0
```

Tutaj również występuje problem rozpoznawania rzadko występujących klas w zbiorze treningowym (klasy 0, 1 oraz 5).


Wykresy dla sztucznej sieci neuronowej z wczesnym zatrzymaniem uczenia

Przeprowadzono analogiczne badania, ale w celu zniwelowania przeuczenia wykorzystano metodę wczesnego zatrzymania uczenia. Hiperparametry $l_rate = 0.005$, $n_epoch=10000$.



W porównaniu do wcześniejszego wykresu widzimy, że dwuwarstwowy perceptron wypada znacznie lepiej na tle pozostałych. Dla innych struktur wzrosło odchylenie standardowe, co oznacza, że bez przeuczenia te modele są mniej stabilne.

Badanie wpływu learning rate na dokładność klasyfikacji dla perceptronu dwuwarstwowego:



Na podstawie wygenerowanego wykresu widzimy małą zmianę dokładności dla $l_rate \in [0.01, 0.015, 0.02, 0.05, 0.1]$. Tak samo, jak na wykresie z różnymi strukturami sieci, odchylenie kwadratowe się powiększyło. Model jest mniej przeuczony.

```
Accuracy on best structure + best l_rate: 0.60
```


```
Label 0: recall = 0.00
Label 1: recall = 0.00
Label 2: recall = 0.71
Label 3: recall = 0.67
Label 4: recall = 0.26
Label 5: recall = 0.00
```

```
Process finished with exit code 0
```


Najlepsza dokładność pozostała na poziomie 60% i zgadywanie klas nie zmieniło się.

Wykresy dla sztucznej sieci neuronowej z wczesnym zatrzymywaniem uczenia i augmentacją danych

Zastosowano augmentację danych aby sprawdzić jak zmieni się dokładność kategoryzacji. Wykorzystano gotowe rozwiązanie próbkowania danych z biblioteki imblearn. Otrzymano w ten sposób zbiór danych wejściowych i etykiet po 433 elementy z każdą etykietą.



Możemy zauważyć na wykresach, że dokładność wszystkich struktur wzrosła oprócz perceptronu dwuwarstwowego. Średnie odchylenie stanowi 1-2%. Najlepszą strukturą jest głęboka szeroka sieć neuronowa z ukrytymi warstwami 11, 36 i 16 neuronów.



Dla głębokiej sieci neuronowej z augmentacją danych najdokładniejszy learning rate stanowi 0.05, chociaż warto zauważyć, że przedział $[0.015; 0.1]$ daje bardzo wysoką dokładność z niskim odchyleniem standardowym.

```
Accuracy on best structure + best l_rate: 0.82
```

```
Label 0: recall = 1.00
```

```
Label 1: recall = 0.92
```

```
Label 2: recall = 0.68
```

```
Label 3: recall = 0.42
```

```
Label 4: recall = 0.91
```

```
Label 5: recall = 0.98
```

```
Process finished with exit code 0
```

Wraz ze wzrostem dokładności modelu wzrosła również dokładność zgadywania tych etykiet, których model nie był wcześniej rozpoznać. Warto zauważyć że trzecia klasa jest rozpoznawana wyraźnie rzadziej (0,67 -> 0,42).