

SPRAWOZDANIE

z ćwiczenia nr 6

“Uczenie się ze wzmocnieniem”

Przedmiot: Wprowadzenie do Sztucznej Inteligencji

Imię i nazwisko: Viktoriia Nowotka

W ramach laboratorium zaimplementowano jeden z algorytmów uczenia ze wzmocnieniem Q-learning w postaci klasy Q-learning, która podczas inicjalizacji przyjmuje jako parametry możliwe akcji agenta, możliwe directions w środowisku, liczbę epizodów, maksymalną dozwoloną liczbę kroków oraz pozycje celu.


Na początku tworzy się środowisko Four Rooms, a także inicjalizuje się możliwe dopuszczalne stany agenta (stanem nie może być pole poza środowiskiem oraz pole na ścianie) i indeksuje się ich wraz z directions.

Uczenie agenta zachowania się w środowisku na podstawie algorytmu Q-learning realizowano w metodzie train(), gdzie przekazuje się hiperparametry szybkości uczenia, współczynnik dyskontowania i epsilon.

Na początku uczenia inicjalizuje zerowa tablica Q w wymiarach indeksy_dop_stanów_wraz_z_direction * ilość_możliwych_akcji. W każdym epizodzie losuje startowy punkt agenta, po czym zaczyna się szukanie ścieżki do celu i aktualizacja tablicy Q. Wybór akcji realizowano sposobem e-greedy.

Po tym, jak agent jest nauczony do zachowania się w środowisku (tzn. tablica Q jest wypełniona danymi w jakim stanie jaka akcja przyniesie najlepszy wynik w długoterminowej perspektywie), można użyć metody run(), żeby sprawdzić jak szybko agent znajdzie cel z pozycji (7,7) do (2,2) domyślnie.

Biorąc pod uwagę duże środowisko (19*19) i dużą ilość pozycji agenta (1444) i losowy punkt początkowy, żeby uzyskać w miarę dokładne sprawdzenie wszystkich stanów i wszystkich akcji weźmiemy 700 epizodów i maksymalną liczbę kroków 500. Szybkość uczenia ustawimy na 0.25, współczynnik dyskontowania na 0.99 oraz epsilon na 0.5.



Rys. 1 – Przykładowy stan agenta w środowisku Four Rooms

```
Agent grid pos: 7; 6 | dir: 2
Episode: 700, step: 0
STOP: reached goal

|
Run finished after 12 steps
Q-learning alg params: episodes=700, max_steps=500 b=0.25, γ=0.99, eps=0.5

Process finished with exit code 0
```

Rys. 2 – uczenie agenta

Z ścieżka (7;7) do (2;2) trwa 10 kroków. Widzimy, że agent dotarł do celu za 12, co jest bardzo dobrym wynikiem. Podczas uczenia agent osiągnął cel 554 razy na 700 epizodów.

Przeprowadzimy eksperymenty związane z wpływem hiperparametrów algorytmu b , γ i ϵ . Żeby wyniki eksperymentów dało się osiągnąć w normalnym czasie, założymy stały punkt początkowy (7; 7) i zmniejszymy liczbę kroków do 250, a liczbę epizodów do 75.

Szybkość uczenia zbadamy dla wartości [0.1, 0.5, 0.9].




Dla pośredniej wartości szybkości uczenia uzyskano najlepsze wyniki, co może wydawać się zaskakujące. Osobiście zakładałam, że parametr beta powinien przyjmować wartości zbliżone do 1. Jednak wyniki eksperymentu mogą się różnić ze względu na stosunkowo małą próbkę danych dla osiągnięcia dobrego poziomu dokładności Q.

Współczynnik dyskontowania zbadamy dla wartości $[0.9, 0.95, 0.975, 0.99]$.



Dla problemu danej trudności najlepszy poziom patrzenia na horyzont jest na poziomie około 40 kroków do przodu.

Epsilon zbadamy dla wartości [0.1, 0.5, 0.9].



Czym mniejszy epsilon, tym lepsze wyniki. To oznacza, że opłaca się agentowi poruszać się po bardziej znanych ścieżkach.

Jednak, jeżeli poziom eksploracji będzie zbyt niski, to agent może nigdy się nie dowiedzieć o istnieniu innej krótszej ścieżki.